

Машинное обучение 1

Контрольная работа (2021 год) — Вариант 1

Задача 1 (2.5 балла)

1. Метод one-vs-all (один против всех) для многоклассовой классификации: Для каждого класса $k = 1, \dots, K$ обучается бинарный классификатор $a_k(x)$, который предсказывает $+1$, если объект относится к классу k , и -1 иначе. При классификации нового объекта выбирается класс, давший максимальный ответ:

$$\hat{y}(x) = \arg \max_{k=1, \dots, K} a_k(x).$$

2. Рассмотрим функции потерь для $y = -1$:

- $L_a(-1, z) = \log(1 + \exp(z))$. Функция монотонно убывает при $z \rightarrow -\infty$, минимум достигается асимптотически при $z \rightarrow -\infty$, поэтому минимальное по модулю значение z не существует (или равно $+\infty$).
- $L_b(-1, z) = \max(0, 1 + z)$. Минимум достигается при $z \leq -1$, минимальное по модулю $z = -1$, $|z| = 1$.
- $L_c(-1, z) = (-z - 1)^2 = (z + 1)^2$. Минимум при $z = -1$, $|z| = 1$.

3. Добавим порог $t = 10$: $\hat{a}(x) = \text{sign}(\langle w, x \rangle - 10)$. Для положительных объектов ($y = +1$) исходный классификатор даёт $\langle w, x \rangle > 0$. Добавление порога может изменить знак, если $0 < \langle w, x \rangle < 10$.

- Для L_a значение может измениться, так как функция потерь зависит от отступа $y \cdot \langle w, x \rangle$.
- Для L_b при больших отступах ($\langle w, x \rangle \geq 1$) значение равно 0, и порог его не изменит, если отступ останется ≥ 1 , то есть $\langle w, x \rangle \geq 11$. В общем случае утверждение неверно.

4. SVM с $C = 1$ относит все объекты к синему классу, вероятно, из-за сильного дисбаланса классов: синий класс составляет большинство, и штраф за ошибку на красных объектах перекрывается выигрышем от правильной классификации синих. Увеличение параметра C может помочь сбалансировать штрафы за ошибки на разных классах.

Задача 2 (2.5 балла)

1. Out-of-bag (OOB) оценка в бэггинге: При построении каждого дерева с помощью бутстрапа часть объектов (в среднем около 37%) не попадает в выборку и является "контрольной" для данного дерева. OOB-ошибка вычисляется как средняя ошибка предсказаний по тем деревьям, которые не видели объект при обучении. Используется для оценки качества модели без отдельной отложенной выборки и для настройки гиперпараметров.

2. Ошибки в формулах:

- В определении s_i должна быть производная по $a_{N-1}(x_i)$, а не по $b_{N-1}(x_i)$.
- Должен быть знак минус: $s_i = -\frac{\partial L(y_i, z)}{\partial z} \Big|_{z=a_{N-1}(x_i)}$.
- В целевой функции для b_N обычно используют среднеквадратичную ошибку: $\sum (b_N(x_i) - s_i)^2$, а не $\frac{1}{\ell} \sum L(s_i, b_N(x_i))$.

3. Для регрессии с MSE:

- Решающее дерево: прогноз в листе — среднее целевых значений. Если все $y_i > 0$, то среднее > 0 , поэтому прогнозы неотрицательны.
- Случайный лес: то же самое, прогнозы неотрицательны.
- Градиентный бустинг: базовые деревья обучаются на сдвигах (псевдо-остатках), которые могут быть отрицательными, поэтому прогнозы отдельных деревьев и итоговой композиции могут быть отрицательными.

4. В XGBoost регуляризация нормы весов в листьях ($\frac{\lambda}{2} \sum b_j^2$) работает, потому что веса подбираются аналитически при фиксированной структуре дерева. В одиночном дереве, обучаемом обычным жадным алгоритмом, веса в листьях определяются как среднее целевых значений, и регуляризация нормы не вписана в процесс обучения. Её добавление потребовало бы пересмотра критерия разбиения и метода подбора прогнозов.

Задача 3 (2.5 балла)

1. Логистическая функция потерь гладкая и выпуклая, её градиент хорошо определён везде, что позволяет использовать градиентные методы оптимизации. Доля ошибок кусочно-постоянна, её градиент равен нулю почти везде, что делает оптимизацию практически невозможной с помощью градиентного спуска.

2.

- *Может ли доля ошибок вырасти, а логистическая ошибка упасть?* Да, это возможно: модель может стать увереннее в правильных ответах, но один объект перестал классифицироваться правильно.
- *Может ли логистическая ошибка вырасти, а доля ошибок упасть?* Тоже возможно: например, модель уменьшила уверенность в правильных ответах, но при этом все ответы остались верными.

3. Пример функции потерь:

$$L(y, a) = \begin{cases} \frac{1}{2}(y - a)^2, & a \leq y, \\ |y - a|, & a > y. \end{cases}$$

Штрафует за завышение прогноза квадратично, а за занижение — линейно, что обеспечивает устойчивость к выбросам при занижении и сильный штраф при завышении. Однако она не везде дифференцируема. Гладкий вариант: $L(y, a) = \frac{1}{2}(y - a)^2 + \frac{1}{2} \log \cosh(a - y)$ с возможной настройкой коэффициентов для асимметрии.

4.

- $L_3 = \sum |w_j|^3$: штрафует большие веса сильнее, чем L_2 , и стремится сделать веса равномерно маленькими. Может давать более разреженные решения, чем L_2 , но менее разреженные, чем L_1 .
- $L_\infty = \max_j |w_j|$: стремится минимизировать максимальный по модулю вес, что приводит к выравниванию весов. Не дифференцируема в точках, где два веса равны по модулю.
- $L_0 = \sum [w_j \neq 0]$: число ненулевых весов. Дает максимально разреженное решение, но задача оптимизации становится NP-трудной (комбинаторная).

Задача 4 (2.5 балла)

Дано:

$$x_i \sim \mathcal{N}(0, \sigma^2), \quad y_i = \varepsilon_i x_i, \quad \varepsilon_i \sim \text{Exp}(\lambda),$$

все ε_i и x_i независимы. Известно: $\mathbb{E}[\varepsilon_i] = \frac{1}{\lambda}$, $\mathbb{D}[\varepsilon_i] = \frac{1}{\lambda^2}$.

Модель:

$$\mu(X)(x) = \frac{1}{\lambda} \left(\sum_{i=1}^{\ell} x_i \right) \text{sign}(x).$$

1. Найдём $\mathbb{E}[y \mid x]$:

$$\mathbb{E}[y \mid x] = \mathbb{E}[\varepsilon x \mid x] = x \cdot \mathbb{E}[\varepsilon] = \frac{x}{\lambda}.$$

2. Шум (noise):

$$\text{Noise} = \mathbb{E}_{x,y}[(y - \mathbb{E}[y \mid x])^2] = \mathbb{E}_x[x^2 \cdot \mathbb{D}[\varepsilon]] = \mathbb{E}_x[x^2] \cdot \frac{1}{\lambda^2} = \sigma^2 \cdot \frac{1}{\lambda^2}.$$

3. Средний ответ модели:

$$\mathbb{E}_X[\mu(X)(x)] = \frac{1}{\lambda} \cdot \mathbb{E}_X \left[\sum_{i=1}^{\ell} x_i \right] \cdot \text{sign}(x) = \frac{1}{\lambda} \cdot 0 \cdot \text{sign}(x) = 0.$$

4. Смещение (bias):

$$\text{Bias}^2 = \mathbb{E}_x[(\mathbb{E}_X[\mu(X)(x)] - \mathbb{E}[y \mid x])^2] = \mathbb{E}_x[(0 - x/\lambda)^2] = \frac{1}{\lambda^2} \mathbb{E}_x[x^2] = \frac{\sigma^2}{\lambda^2}.$$

5. Разброс (variance):

$$\text{Var} = \mathbb{E}_x[\mathbb{D}_X(\mu(X)(x))] = \mathbb{E}_x \left[\text{sign}^2(x) \cdot \frac{1}{\lambda^2} \cdot \mathbb{D}_X \left(\sum_{i=1}^{\ell} x_i \right) \right] = \frac{1}{\lambda^2} \cdot 1 \cdot \ell \sigma^2 = \frac{\ell \sigma^2}{\lambda^2}.$$

Итоговые компоненты разложения ошибки:

$\text{Noise} = \frac{\sigma^2}{\lambda^2}, \quad \text{Bias}^2 = \frac{\sigma^2}{\lambda^2}, \quad \text{Variance} = \frac{\ell \sigma^2}{\lambda^2}.$
